人工智能导论 · 补充阅读：向量检索评测指标

一、为什么需要评测检索质量

RAG 系统的回答质量首先取决于检索质量：如果召回的文本块与问题无关，再强的大模型也无法给出正确答案，反而可能被无关资料误导。因此在调整 chunk_size、top-k 等参数时，需要用可量化的指标衡量检索效果。

二、精确率与召回率

精确率（Precision）：召回的 top-k 个文本块中，真正与问题相关的块所占的比例。精确率低意味着检索噪声大，会把无关内容塞进提示词。

召回率（Recall）：知识库中所有相关文本块里，被成功召回的比例。召回率低意味着关键资料漏检，模型必然“无米下锅”。

两者通常此消彼长：增大 top-k 往往能提高召回率，但会拉低精确率。

人工智能导论 · 补充阅读：向量检索评测指标（续）

三、平均排名与命中序号

除了比例指标，还应关注“第一个相关块出现在第几位”。相关内容排在越靠前的位置，越有利于生成；如果相关块排在第五名之后，即使被召回，也容易在长上下文中被模型忽略。

四、课程实践建议

1. 准备 10 至 20 个典型问题，人工标注每个问题对应的正确文本块；
2. 固定 Embedding 模型，只改变切分参数与 top-k，做对照实验；
3. 先保证正确块进入 top-4，再追求精确率，避免一上来同时改动多个参数；
4. 若检索正确但回答仍出错，问题才出在生成环节，应排查提示词模板。

思考题：top-k 从 3 增大到 10，精确率和召回率可能分别如何变化？